

Анализ временных рядов — Домашнее задание 1


Базовые понятия, экспоненциальное сглаживание и ARIMA

Выполнила: Вагапова Деши | Датасет: Kaggle Store Item Demand Forecasting Challenge | item = 29 | столбец: sales

Исследуются 4 временных ряда — две комбинации по признаку store (фиксированный магазин №1 и сумма продаж по всем 10 магазинам) на две частоты наблюдений (дневная и месячная). Тестовая выборка (последние 24 наблюдения для дневных рядов, 12 — для месячных) отложена и использовалась только для финальной оценки прогноза в частях 3, 5 и 6.

Серия	Магазин	Частота	Сезонный период m	Train	Test
A	store = 1 (фиксированный)	дневная	7	1802	24
B	store = 1 (фиксированный)	месячная	12	48	12
C	сумма по всем store	дневная	7	1802	24
D	сумма по всем store	месячная	12	48	12

Часть 1 — Разведочный анализ




Серия	Среднее	СКО	Наклон тренда (ед./шаг)	Рост 2013 → 2017
A: store=1, дневная	63.09	17.28	0.0132	+36.2%
B: store=1, месячная	1919.93	420.62	12.4266	+36.2%
C: сумма по store, дневная	696.19	172.67	0.1430	+35.5%
D: сумма по store, месячная	21187.33	4617.41	134.6934	+35.5%

Все четыре ряда показывают устойчивый растущий тренд и выраженную годовую сезонность (спад в начале года, пик летом); дневные ряды дополнительно содержат недельные колебания. Коэффициент вариации стабилен год к году (без резких структурных сдвигов), при этом абсолютный размах сезонных колебаний растёт вместе с уровнем тренда — это признак мультипликативной сезонности, что подтверждается в части 2. Явных выбросов/аномалий, не объяснимых сезонностью, не обнаружено.

Часть 2 — Наивная декомпозиция

A_store1_daily: декомпозиция (period=7)




Пример (серия A): аддитивная (слева) и мультипликативная (справа) декомпозиция

Серия	СКО ост. (аддит.)	СКО ост. (мульти.)	Лучше	Ljung-Box p (ост.)	Похож на б.шум?
A: store=1, дневная	7.45	7.34	multiplicative	0.0000	нет
B: store=1, месячная	62.18	41.32	multiplicative	0.2724	да
C: сумма по store, дневная	32.78	27.65	multiplicative	0.0000	нет
D: сумма по store, месячная	525.98	306.92	multiplicative	0.0501	да

Во всех четырёх сериях мультипликативная декомпозиция даёт меньшее СКО остатка в шкале исходного ряда, что согласуется с наблюдением из части 1 (амплитуда сезонности растёт с уровнем ряда) — во всех дальнейших частях используется мультипликативная модель. Для дневных рядов (A, C) остаток декомпозиции статистически значимо коррелирован (Ljung-Box $p < 0.001$) — наивная модель с фиксированным периодом 7 не улавливает праздничные эффекты и более тонкую структуру. Для месячных рядов (B, D) остаток ближе к белому шуму, особенно для D.

Часть 3 — Экспоненциальное сглаживание Хольта-Уинтерса

Серия	Сезонность	α	β	γ	RMSE	MAE	MAPE
A: store=1, дневная	mul	0.166	0.000	0.000	9.72	8.47	15.76%
B: store=1, месячная	mul	0.333	0.000	0.000	73.23	58.34	2.73%
C: сумма по store, дневная	mul	0.454	0.000	0.000	31.05	26.98	4.48%
D: сумма по store, месячная	mul	0.484	0.000	0.000	896.66	819.41	3.40%




Пример (серия D): прогноз Holt-Winters с 95% интервалом предсказания

Во всех четырёх сериях трендовый (β) и сезонный (γ) параметры сглаживания оптимизатор прижал к нулю — значит, вся адаптация модели к новым наблюдениям идёт только через уровень (α), тогда как наклон тренда и форма сезонного профиля, оценённые при инициализации, считаются стабильными на всём горизонте обучения. α растёт с частотой агрегации и объёмом ряда (0.166 $\rightarrow$ 0.484), то есть чем более "шумный" и короткий по характерному масштабу ряд, тем быстрее модель переоценивает уровень по новым наблюдениям.

Часть 4 — ACF, PACF и стационарность

Серия	ADF p (исх.)	KPSS p (исх.)	Выбрано d, D	Кандидатные порядки
A: store=1, дневная	0.0751	0.0100	d=0, D=1	p=2, q=5, P=1, Q=1
B: store=1, месячная	0.8158	0.0710	d=0, D=1	p=1, q=2, P=1, Q=0
C: сумма по store, дневная	0.0414	0.0100	d=1, D=0	p=5, q=1, P=1, Q=1
D: сумма по store, месячная	0.8080	0.0746	d=1, D=1	p=0, q=0, P=0, Q=0

A_store1_daily: ACF/PACF на каждой стадии дифференцирования



Пример (серия A): ACF/PACF на каждой стадии дифференцирования (d=0,D=0 $\rightarrow$ d=0,D=1)

H_0 теста ADF — ряд имеет единичный корень (нестационарен); H_0 теста KPSS — ряд стационарен вокруг константы. Для всех серий, кроме C, исходный ряд не проходит хотя бы один из тестов на 5%-уровне; для C тесты дают противоречивый результат (ADF отвергает H_0 , KPSS — нет), что типично для ряда с детерминированным трендом при KPSS-регрессии на константу. Во всех случаях дифференцирование (сезонное и/или обычное) устраняет нестационарность — оба теста после этого согласованно указывают на стационарность.

Часть 5 — Моделирование ARIMA / SARIMA

A: store=1, дневная

Кандидат	Порядок	AIC	BIC
Ручная (по ACF/PACF)	SARIMA(2, 0, 5)x(1, 1, 1, 7)	12808.9	12863.7
auto_arima	SARIMA(0, 0, 2)x(1, 1, 1, 7)	13181.2	13208.7
Вариант (q+1)	SARIMA(2, 0, 6)x(1, 1, 1, 7)	12913.1	12973.4

B: store=1, месячная

Кандидат	Порядок	AIC	BIC
Ручная (по ACF/PACF)	SARIMA(1, 0, 2)x(1, 1, 0, 12)	257.8	263.5
auto_arima	SARIMA(1, 0, 0)x(1, 1, 0, 12)	260.1	263.5
Вариант (q+1)	SARIMA(1, 0, 3)x(1, 1, 0, 12)	258.0	264.9

C: сумма по store, дневная


Кандидат	Порядок	AIC	BIC
Ручная (по ACF/PACF)	SARIMA(5, 1, 1)x(1, 0, 1, 7)	18212.0	18261.5
auto_arima	SARIMA(0, 1, 1)x(1, 0, 1, 7)	18240.4	18262.4
Вариант (q+1)	SARIMA(5, 1, 2)x(1, 0, 1, 7)	18414.1	18469.0

D: сумма по store, месячная

Кандидат	Порядок	AIC	BIC
Ручная (по ACF/PACF)	SARIMA(0, 1, 0)x(0, 1, 0, 12)	528.3	529.8
auto_arima	SARIMA(0, 1, 0)x(0, 1, 1, 12)	336.5	338.7
Вариант (q+1)	SARIMA(0, 1, 1)x(0, 1, 0, 12)	514.2	517.2

Диагностика и прогноз финальной (лучшей по AIC) модели

Серия	Финальная модель	Ljung-Box p	Jarque-Bera p	RMSE (test)	MAPE (test)
A: store=1, дневная	SARIMA(2, 0, 5)x(1, 1, 1, 7)	0.4683 (нет автокорр.)	0.002354	9.83	15.49%
B: store=1, месячная	SARIMA(1, 0, 2)x(1, 1, 0, 12)	0.0002 (есть автокорр.)	0.000000	59.87	2.15%
C: сумма по store, дневная	SARIMA(5, 1, 1)x(1, 0, 1, 7)	0.5413 (нет автокорр.)	0.000000	99.90	14.92%
D: сумма по store, месячная	SARIMA(0, 1, 0)x(0, 1, 1, 12)	0.4497 (нет автокорр.)	0.000000	583.63	2.29%



Пример (серия C): ACF и гистограмма остатков финальной SARIMA-модели

Во всех сериях, кроме В, тест Льюнга-Бокса не отвергает гипотезу об отсутствии автокорреляции остатков ($p > 0.05$) — остатки ведут себя как белый шум с точки зрения независимости. Тест Харке-Бера почти везде отвергает нормальность (тяжёлые хвосты, положительный эксцесс) — это связано с редкими крупными всплесками спроса (например, в праздники), которые модель недооценивает, но которые не создают систематической предсказуемой структуры. Для серии В (48 обучающих наблюдений) все три кандидата показывают значимую остаточную автокорреляцию — короткий месячный ряд не позволяет надёжно оценить более сложную сезонную ARMA-структуру; при этом точность прогноза на тесте остаётся приемлемой ($MAPE \approx 2.2\%$).

Часть 6 — Сравнение Holt-Winters и SARIMA



Серия	Модель	RMSE	MAE	MAPE	Победитель
A: store=1, дневная	Holt-Winters	9.72	8.47	15.76%	Holt-Winters
	SARIMA	9.83	8.41	15.49%	
B: store=1, месячная	Holt-Winters	73.23	58.34	2.73%	SARIMA
	SARIMA	59.87	42.89	2.15%	
C: сумма по store, дневная	Holt-Winters	31.05	26.98	4.48%	Holt-Winters
	SARIMA	99.90	89.26	14.92%	
D: сумма по store, месячная	Holt-Winters	896.66	819.41	3.40%	SARIMA
	SARIMA	583.63	492.49	2.29%	

Holt-Winters побеждает по RMSE на сериях А и С (дневная частота), SARIMA — на В и D (месячная частота). На дневных рядах с сильным трендом (особенно С) точечные ARIMA-модели без явного дрейфа хуже экстраполируют устойчивый рост уровня на 24-дневном горизонте, чем Holt-Winters с явно оцененным при инициализации трендом; на более коротких и сглаженных месячных рядах, наоборот, гибкая SARIMA-структура с сезонным дифференцированием точнее ловит динамику. Общий вывод: ни одна из моделей не доминирует на всех четырёх сериях — выбор модели целесообразно делать по каждому конкретному ряду отдельно, ориентируясь на его частоту и структуру, а не применять один и тот же метод по умолчанию.

Общие выводы

- 1) Все четыре ряда нестационарны в исходном виде (растущий тренд + сезонность) и приводятся к стационарности одним шагом обычного и/или сезонного дифференцирования.
- 2) Сезонность во всех случаях лучше описывается мультипликативной, а не аддитивной моделью.
- 3) Экспоненциальное сглаживание Хольта-Уинтерса даёт конкурентоспособный, а на дневных рядах — лучший прогноз, несмотря на простоту модели; его параметры β , γ у всех серий уходят в 0, то есть модель эффективно вырождается в SES с фиксированными трендом/сезонностью.
- 4) SARIMA, подобранная по минимуму AIC, стабильно лучше на месячных агрегатах, но на дневных данных проигрывает Holt-Winters — точный выбор модели зависит от частоты и характера конкретного ряда, что подтверждает необходимость сравнивать несколько подходов, а не полагаться на один метод по умолчанию.